GENCI
Le calcul intensif au service de la connaissance

Demande d'attribution de ressources de calculs

Ce formulaire sert à décrire **scientifiquement et techniquement** sa demande pour trois types d'allocations différentes :

- **AD** (Allocation Dynamique).

Attention,

- ce document est limité à 15 pages et doit être téléversé en pdf dans votre espace utilisateur en lien avec votre demande sur www.edari.fr
- Il est confidentiel et dédié uniquement à l'expertise.
- ce document est **obligatoire pour toutes demandes d'AR et AS** mais est facultatif pour les AD.
- Les exigences de ce dossier ne coïncident pas totalement avec celles de l'ANR ou d'autres soutiens européens, l'utilisation de copier-coller est à proscrire.

Pour plus de détails, vous pouvez consulter cette documentation

1. Description du projet

1.1. Informations générales

Titre du projet : Narrative Geometry

Responsable scientifique : Charles-Albert Lehalle (Professeur CE, CMAP, Ecole Polytechnique)

1.2. Résumé

Dans la continuité de nos travaux récents sur la modélisation géométrique des corpus textuels — qui ont permis de résoudre le biais de corrélation inter-narrative grâce à une orthogonalisation sur la variété de Stiefel —, ce projet vise à **passer à l'échelle du calcul intensif (HPC)** pour cartographier en temps réel la propagation des récits complexes à l'échelle de téraoctets de données textuelles.

Si notre méthodologie algébrique a prouvé son efficacité sur des corpus historiques de taille modérée (comme le *News Category Dataset*), son application à des flux massifs et continus

(actualités mondiales, réseaux sociaux, corpus scientifiques ou rapports institutionnels sur plusieurs décennies) se heurte à un verrou de calcul critique : l'optimisation globale sur des variétés riemanniennes de grande dimension et la gestion dynamique de matrices d'embeddings ultra-larges.

Ce projet de calcul haute performance ambitionne de :

- **Développer des algorithmes distribués** capables d'exécuter l'orthogonalisation max-min et l'estimation non biaisée de la prévalence des narratifs sur des volumes de données massifs.
- **Modéliser la dynamique non linéaire** de l'émergence, de la compétition et de l'extinction des récits sociétaux ou technologiques.
- **Fournir un outil open-source de pointe** pour l'analyse prédictive et la détection précoce de signaux faibles informationnels, au service de la recherche académique et des politiques publiques.

L'accès aux ressources de calcul de GENCI/eDARI est indispensable pour lever ces verrous algorithmiques et mener à bien les simulations à grande échelle qui valideront la robustesse de notre modèle génératif linéaire étendu.

2. Présentation scientifique détaillée

Longueur de 2 à 4 pages. Si le projet se décompose en sous-projets, 2 pages additionnelles maximum par sous-projet.

Voici la description scientifique détaillée de votre projet de continuation, structurée pour s'intégrer parfaitement dans un dossier de recherche ou une proposition d'allocation de calcul de grande envergure.

---

1. Contexte et Problématique de Continuation

Dans la continuité des travaux fondateurs présentés dans le papier de référence, ce projet vise à lever les verrous méthodologiques et algorithmiques liés à l'analyse à grande échelle de corpus textuels évolutifs. Notre méthodologie précédente a introduit un cadre algébrique rigoureux — fondé sur une orthogonalisation globale des vecteurs de narratifs sur la *variété de Stiefel* via une optimisation de type *max-min* — pour résoudre le biais de corrélation inhérent aux approches naïves par similarité cosinus.

Toutefois, pour passer d'une validation sur des jeux de données historiques de taille modérée (comme le *News Category Dataset* sur la période 2012–2018) à une modélisation dynamique continue sur des téraoctets de données textuelles mondiales, le projet s'articule autour de deux axes de recherche majeurs et successifs.

2. Programme de Recherche et Expérimentations à Grande Échelle

Dans sa première phase, le projet déploie l'infrastructure et l'appareillage méthodologique sur un ensemble étendu de dimensions, de modèles et de corpus :

- **Généralisation de l'orthogonalisation de Stiefel et des alternatives :** Implémentation et comparaison systématique de l'optimisation sur la variété de Stiefel avec d'autres méthodes de projection ou de régularisation (telles que des variantes de Gram-Schmidt contraintes ou des relaxations de type Procrustes améliorées par des fonctions *softmin*), afin d'évaluer le compromis entre fidélité des narratifs et orthogonalité parfaite.

- **Diversification des espaces d'embeddings :** Extension des expérimentations au-delà de *ModernBERT*, en testant des représentations sémantiques alternatives et de pointe, notamment des encodeurs lexicaux et denses combinés (tels que **SPLADE** pour la représentation creuse et d'autres LLM bi-encodeurs récents), afin de mesurer l'invariant de la structure géométrique face au choix du modèle de langue sous-jacent.

- **Diversification des corpus textuels :** Passage à l'échelle sur plusieurs bases de données de textes diversifiées (archives de presses internationales, corpus de rapports institutionnels sur plusieurs décennies, et flux de données textuelles massifs) pour tester la robustesse des estimateurs non biaisés de prévalence ($p_i(t)$) et de co-occurrence ($p_{ij}(t)$).

- **Clusters non supervisés en amont :** Constitution préalable de clusters non supervisés dans l'espace des embeddings pour identifier de manière endogène des structures thématiques candidates avant d'appliquer l'orthogonalisation globale.

- **Fenêtres temporelles glissantes :** Implémentation de versions dynamiques par fenêtres temporelles glissantes (moyennes mobiles exponentielles et discrétisations adaptatives) pour suivre en continu l'émergence, la compétition et l'extinction des récits sociétaux.

3. Extension Théorique : Intégration de la Structure de Série Temporelle

Dans un second temps, une fois que les travaux théoriques en cours — visant à incorporer intrinsèquement une structure stochastique et de série temporelle à la théorie générative — auront abouti, le projet procèdera à une refonte complète des expérimentations :

- **Nouvelle décomposition dynamique :** Réitération de l'ensemble des pipelines d'optimisation et d'estimation en s'appuyant sur cette nouvelle formulation théorique intégrant la dynamique temporelle directement dans le modèle génératif sous-

jacent.

- **Validation contrefactuelle avancée :** Exploitation de ces nouveaux estimateurs pour affiner l'analyse des ruptures de pente, la spécificité des chocs narratifs, et la réduction des bruits de corrélation sur des chronologies complexes (par exemple, les cycles électoraux ou les crises économiques mondiales).

Ce programme intensif nécessite des ressources de calcul haute performance (HPC) substantielles, tant sur partitions CPU (pour le traitement et le parsing des corpus massifs) que sur partitions GPU (pour l'accélération des descentes de gradient riemanniennes sur la variété de Stiefel et l'inférence des embeddings de grands modèles de langue), justifiant pleinement la présente demande d'allocation dynamique auprès de GENCI/eDARI.

3. Présentation technique détaillée

3.1. Méthode numérique et implémentations

Longueur de 4 à 6 pages. Si la méthode utilisée est très connue dans le domaine scientifique en question ou si le logiciel utilisé est compilé par le centre, l'explication peut être plus courte.

Les méthodes numériques et algorithmiques mobilisées dans ce projet reposent sur des briques logicielles standard et des algorithmes d'optimisation riemannienne bien établis dans la littérature, capitalisant sur les environnements pré-compilés et optimisés des centres de calcul (IDRIS et TGCC).

---

1. Optimisation sur la variété de Stiefel et approximation Softmin

Le cœur méthodologique du projet réside dans la résolution du problème d'optimisation globale *max-min* sur la variété de Stiefel $\text{St}(n,d) = \{V \in \mathbb{R}^{n \times d} : V V^\top = I_n\}$ pour orthogonaliser les vecteurs de narratifs.

- **Relaxation et gradient :** La fonction objective non différentiable est lissée via une approximation *softmin*paramétrée par une température $\tau > 0$.

- **Descente de gradient riemannienne :** L'algorithme met en œuvre des étapes classiques de calcul du gradient euclidien, de projection sur l'espace tangent, et de rétraction par décomposition QR pour garantir le maintien des contraintes d'orthonormalisation à chaque itération, conformément aux standards de l'optimisation sur variétés (Absil et al., Boumal).

2. Inférence et traitement des embeddings (ModernBERT et SPLADE)

- **Génération des représentations :** L'extraction des embeddings textuels à grande échelle (corpus *HuffPost* et flux continus) s'appuie sur des modèles de langue de pointe (ModernBERT et SPLADE).

- **Framework d'apprentissage :** L'implémentation logicielle utilise **PyTorch** couplé aux bibliothèques d'accélération **CUDA** et **cuDNN** pour optimiser le passage dans les réseaux de transformateurs.

3. Exploitation des architectures HPC (IDRIS / TGCC)

Le passage à l'échelle sur les partitions de calcul haute performance s'organise de la manière suivante :

- **Partitions GPU (Jean Zay V100/A100, Joliot-Curie/Irene V100) :** Les tâches lourdes d'inférence des LLM et les descentes de gradient riemanniennes sur matrices de grande dimension sont parallélisées en multi-GPU grâce à la bibliothèque **NCCL** et au module torch.nn.parallel.

- **Partitions CPU (Jean Zay CSL, Irene Rome) :** Le prétraitement textuel, le parsing des corpus volumineux, la tokenisation et la gestion des structures de données indexées (via **HDF5** et des scripts Python vectorisés avec **Intel-MKL** et **OpenMPI**) sont exécutés sur les nœuds CPU multi-cœurs.

- **Environnements logiciels :** L'ensemble des codes s'appuie exclusivement sur des environnements modulaires déjà compilés et maintenus par les centres (compilateurs GCC, chaînes Intel, environnements Python/Anaconda dédiés), garantissant une portabilité et une efficacité immédiates sur les machines cibles.

3.2. Justification de l'usage des ressources sur la partition demandée

Longueur d'une et deux pages.

Vous pouvez (obligatoire pour des demandes de plus de 20 Mh CPU ou 500 kh GPU) :
:

- *fournir les courbes de scalabilité sur l'architecture cible,*

- *justifier le besoin de l'architecture demandée notamment la génération de GPU et le modèle (AMD VS NVIDIA)*

- *confirmer que votre consommation sera bien linéaire au cours de l'année, sinon justifiez-la (dans le cas de non linéarité, le centre ne pourra pas garantir la disponibilité des heures attribuées par GENCI).*

3.3. Plan de gestion de données (DMP)

À titre indicatif, mais fortement conseillé si vos demandes en stockage sont conséquentes

3.4. Bibliographie

Voici une sélection restreinte des textes essentiels tirés de votre bibliographie, mise en forme pour être copiée-collée directement dans un document Word :

- **Li, Mengda, and Charles-Albert Lehalle.** "Mathematics of Embeddings: Spillover of Polarities over Financial Texts." *Reviews In Modern Quantitative Finance* (2024): 151-188.
- **Shiller, Robert J.** *Narrative Economics: How Stories Go Viral and Drive Major Economic Events*. Princeton University Press, 2020.
- **Boumal, Nicolas.** *An Introduction to Optimization on Smooth Manifolds*. Cambridge University Press, 2023.
- **Absil, P.-A., R. Mahony, and R. Sepulchre.** *Optimization Algorithms on Matrix Manifolds*. Princeton University Press, 2009.
- **Wen, Zaiwen, and Wotao Yin.** "A Feasible Method for Optimization with Orthogonality Constraints." *Mathematical Programming* 142, no. 1--2 (2013): 397--434.
- **Warner, Benjamin, Anirudh Mishra, Alessandro Stolfo, and others.** "Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference." arXiv preprint arXiv:2412.13663 (2024).
- **Ash, Elliott, Germain Gauthier, and Philine Widmer.** "Relatio: Text Semantics Capture Political and Economic Narratives." *Political Analysis* 32, no. 1 (2024): 115--132.